TI3093 Praktikum Perancangan Sistem Terintegrasi III 2025

Modul 1: Peramalan Permintaan Pasar

Program Studi Teknik Industri
Fakultas Teknologi Industri
Institut Teknologi Bandung

HARAP DIPERHATIKAN!

Segala bentuk plagiarisme maupun kecurangan akademis lainnya akan dikenakan sanksi sesuai peraturan yang berlaku di ITB. **Tidak ada toleransi sedikit pun.**

ATURAN DASAR

- Praktikan menggunakan kemeja dan sepatu saat mengikuti responsi, praktikum, dan asistensi
- Keterlambatan dalam menghadiri responsi, praktikum, serta pengumpulan laporan akan mengakibatkan pengurangan poin secara linear (satu poin nilai akhir per satu menit keterlambatan)
- Jika berhalangan hadir dalam rangkaian kegiatan praktikum, hubungi **PJ Modul 1: Ohanprada Hebrizky Sitorus (13422054)**, **Christopher Nathan Sancoyo (13422083)**, atau **Marella Parahita Dewanni (13422125).** Sertakan surat izin dokter untuk alasan sakit atau surat izin bertanda tangan orang tua untuk alasan izin sebelum hari Kamis, 23 September 2025 pukul 18.00 WIB.

DAFTAR ISI

ATURAN DASAR 2
TUJUAN PRAKTIKUM 5
PENDAHULUAN 5
Definisi Peramalan 5
Posisi Modul dalam Siklus Manufaktur 5
Diagram Alir Peramalan 6
ANALISIS UNIVARIAT, BIVARIAT, DAN MULTIVARIAT 7
POLA DATA 8
DATA PREPROCESSING 9
METODE PERAMALAN 10
Klasifikasi Metode Peramalan 10
Metode Peramalan Kualitatif 11
Konsep Peramalan Kuantitatif 11
Metode Peramalan Kuantitatif 12
Metode Peramalan Kausal 12
Metode Peramalan *Time Series* 12
Model Untuk Pola Data Horizontal 12
Naïve 12
Simple Moving Average 13
Single Exponential Smoothing 13
Weighted Moving Average 13
Model Untuk Pola Data Tren 14
Double Exponential Smoothing (Using Holt's Method) 14
Linear Regression with Time 14
Model Untuk Pola Data *Seasonal* 15
Seasonal Naïve 15
Holt's Winter Method (Triple Exponential Smoothing) 15
Hyperparameter & Parameter 16
N-Step Forecasting & 1 Step Forecasting 17
UKURAN PERFORMANSI HASIL PERAMALAN 17
VERIFIKASI HASIL PERAMALAN 18
PERBEDAAN KORELASI, HUBUNGAN SEBAB-AKIBAT, DAN PERAMALAN 21
Perbedaan Korelasi dan Hubungan Sebab-Akibat 21
Confounded Predictors 22
Peramalan dan Multikolinearitas 22

PERAMALAN *TIME-SERIES* JANGKA PENDEK DAN JANGKA PANJANG 23
Time Series Jangka Pendek 23
Time Series Jangka Panjang 23
PERAMALAN MENGGUNAKAN EXCEL 23
Estimasi *Hyperparameter* 23
Peramalan 24
PERALATAN PRAKTIKUM 25
PROSEDUR PRAKTIKUM 25
SUSUNAN TATA TULIS LAPORAN 25
REFERENSI 28

TUJUAN PRAKTIKUM

Tujuan dari praktikum modul 1 PPST III adalah sebagai berikut.

1. Praktikan memahami berbagai metode peramalan permintaan pasar.
2. Praktikan mampu memilih metode peramalan permintaan pasar yang tepat.
3. Praktikan mampu menggunakan metode peramalan permintaan pasar.
4. Praktikan mampu mengevaluasi performansi metode peramalan permintaan pasar.

PENDAHULUAN

Definisi Peramalan

Peramalan adalah aktivitas yang dilakukan untuk memprediksi kejadian yang akan terjadi pada masa yang akan datang. Pada produksi, peramalan digunakan untuk memprediksi jumlah permintaan dari suatu produk sebagai dasar yang digunakan untuk menentukan target volume produksi beserta strategi untuk mencapai target tersebut. Kesalahan dalam proses peramalan dapat berakibat pada kesalahan penentuan target atau strategi. Kesalahan peramalan dapat berdampak terhadap tiga aspek yaitu dampak terhadap perencanaan, kapasitas, dan inventori (Kerkkänen, 2009). Dampak terhadap inventori yaitu jumlah inventori yang berlebih dapat meningkatkan *inventory holding cost* sedangkan kekurangan inventori dapat menyebabkan terjadinya *lost sales*.

Konsep dasar dari peramalan adalah menggunakan pola pada fakta atau data historis pada masa lalu untuk memprediksi kondisi pada masa yang akan datang dengan asumsi bahwa pola tersebut akan berulang kembali di kemudian hari. Pada beberapa kasus, data historis tidak tersedia sehingga diperlukan metode lain untuk memprediksi jumlah permintaan.

Secara garis besar, peramalan dapat dikelompokkan menjadi dua, yaitu metode peramalan kualitatif dan metode peramalan kuantitatif. Praktikum kali ini hanya akan berfokus pada peramalan kuantitatif dengan model *time-series*. Akan tetapi, baik peramalan kuantitatif dengan model kausal maupun peramalan kualitatif tetap disajikan pada modul ini untuk memperjelas perbedaan antar metode peramalan.

Diagram Alir Peramalan

Peramalan umumnya dilakukan dalam tahapan umum sebagai berikut.

1. Pendefinisian Masalah
   Tahap pertama dalam melakukan peramalan adalah memahami konteks masalah yang akan diselesaikan dengan hasil peramalan, bagaimana hasil peramalan akan digunakan, siapa yang membutuhkan hasil peramalan, dan bagaimana hasil peramalan bersesuaian dengan fungsional organisasi.
2. Pengumpulan Data dan Informasi
   Setelah masalah telah terdefinisi dengan baik, maka dapat dikumpulkan data yang bersesuaian. Data yang dibutuhkan terdiri dari (1) data statistik, dan (2) informasi *expert judges* yang mengumpulkan dan menggunakan data atau menggunakan hasil peramalan. Semakin terkini data yang dikumpulkan, maka akan semakin berguna dan relevan terhadap masalah.
3. Preliminary Analysis
   Tahapan ini merupakan tahapan untuk mempersiapkan peramalan data dengan melakukan pemetaan pola data. Dalam pemetaan ini, terdapat beberapa pertanyaan kunci yang harus dijawab yaitu, (1) bagaimana hasil pola data berdasarkan pemetaan, (2) apakah terdapat tren pada data, (3) apakah ada periode siklis/seasonalitas yang ditemukan, (4) apakah terdapat outlier pada data, apakah keberadaannya dapat dijelaskan oleh *expert judges*, dan (5) bagaimana hubungan antar variabel.
4. Pemilihan dan Penyesuaian Model
   Tahap pemilihan model dilakukan berdasarkan hasil pada tahap sebelumnya yaitu hasil pemetaan pola data. Model yang dipilih akan disesuaikan dengan pola data historis. *Common practices* yang terjadi adalah memilih 2-3 model sesuai pola data untuk dibandingkan. Peramalan dilakukan berdasarkan model yang telah ditentukan.
5. Evaluasi Model Peramalan
   Sebelum melakukan peramalan, perlu dilakukan estimasi parameter sesuai model yang dipilih. Selanjutnya, peramalan dapat dilakukan. Untuk menentukan model yang terbaik dan hasilnya digunakan sebagai data peramalan, akan dilakukan *assesment* dari akurasi peramalan melalui perhitungan nilai *error*.

Pada praktikum ini, tahapan akan dimulai dari *preliminary analysis*, dengan asumsi telah tersedia data permintaan historis yang akan digunakan. Berikut merupakan diagram alir dari proses peramalan permintaan.

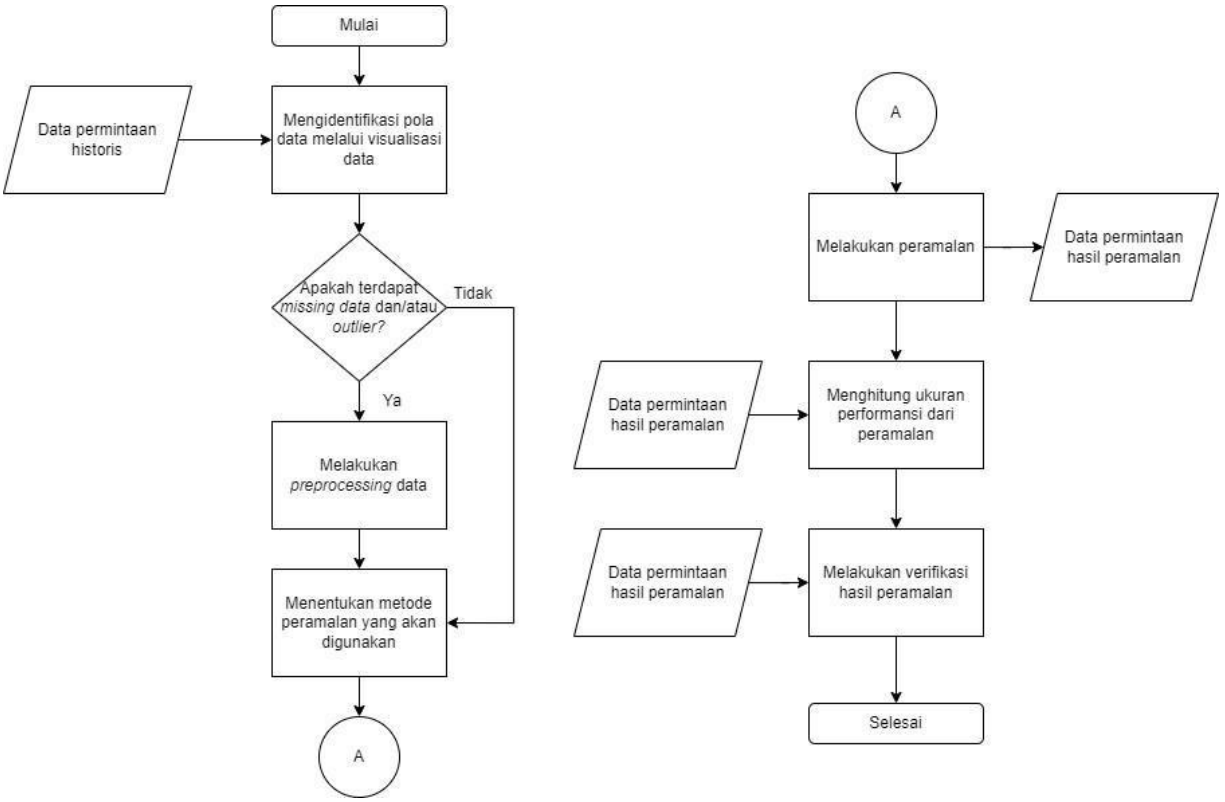

Gambar 2 Diagram Alir Proses Peramalan Permintaan

ANALISIS UNIVARIAT, BIVARIAT, DAN MULTIVARIAT

Sebelum memasuki proses peramalan, perlu diketahui bahwa secara umum, analisis data terbagi menjadi 3 bagian berdasarkan banyaknya variabel yang terlibat. Analisis univariat hanya memiliki satu variabel yang terlibat dalam data; analisis bivariat memiliki dua variabel yang terlibat; sedangkan analisis multivariat memiliki lebih dari dua variabel yang terlibat dalam satu set data.

Sebagai contoh, data univariat merupakan kumpulan persentase *scrap* harian dari proses produksi tripod. Penjelasan data univariat menggunakan ukuran pemusatan data (*mean, median, mode*) dan ukuran penyebaran data (jangkauan, standar deviasi, dan lainnya).

Data bivariat memiliki dua jenis variabel yang berbeda. Tipe analisis bivariat bertujuan untuk mengetahui hubungan kausal antar dua variabel. Contoh dari set data bivariat adalah tingkat konsumsi energi pabrik dan *throughput* produksi.

Data multivariat memiliki lebih dari dua variabel. Contoh dari set data multivariat adalah tingkat konsumsi energi pabrik, *throughput* produksi, tingkat okupansi pekerja, dan derajat perbedaan suhu pabrik dan suhu luar ruangan.

Pada data *time-series*, pemahaman data univariat, bivariat, dan multivariat tetap sama. Sehingga pada kasus peramalan permintaan pasar, peramalan terbatas pada data univariat – seperti yang dipelajari pada TI3093 Perencanaan & Pengendalian Produksi. Peramalan data univariat berbasis waktu hanya mempertimbangkan pola data dalam tiap titik waktu.

POLA DATA

Langkah pertama dalam melakukan proses peramalan adalah mengidentifikasi pola data. Pola data permintaan akan menentukan metode peramalan yang akan digunakan. Oleh karena itu, untuk dapat menentukan metode peramalan yang tepat, diperlukan identifikasi pola data terlebih dahulu. Beberapa jenis pola data yang dapat terbentuk dapat dilihat pada Tabel 1.

Tabel 1 Jenis Pola Data

Pola Data	Definisi	Gambar
Horizontal	Pola data horizontal terjadi apabila suatu data hasil observasi berfluktuasi di sekitar tingkatan (rata-rata) yang konstan.	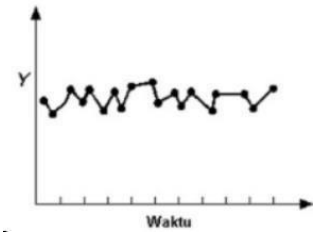
Tren	Pola data tren terjadi apabila suatu data memiliki kecenderungan meningkat atau menurun dari waktu ke waktu.	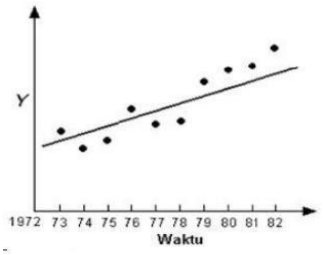
Seasonal	Pola data *seasonal* atau musiman terjadi saat suatu deret data dipengaruhi oleh faktor musiman, misalnya kuartal waktu tertentu, mingguan, atau bulanan. Contoh produk yang mengikuti pola ini adalah penjualan baju koko yang akan meningkat pada saat mendekati hari raya lebaran.	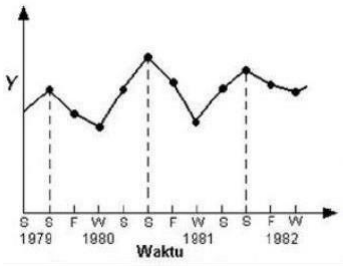
Cyclical	Pola data siklis memiliki pola yang identik dengan *seasonal*. Perbedaannya, interval pengulangan siklusnya terjadi dalam jangka waktu yang lebih lama (lebih dari satu tahun).	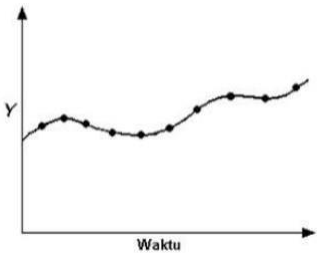

DATA PREPROCESSING

Pada *data preprocessing*, dilakukan identifikasi abnormalitas yang terbagi menjadi dua aktivitas, yaitu (1) perlakuan *missing data* dan (2) perlakuan *outlier*.

Dalam proses pengumpulan data, abnormalitas menyebabkan data tidak dapat digunakan dalam proses peramalan. Abnormalitas membuat data mengalami penyimpangan dari pola yang seharusnya. Sebagai contoh, dalam peramalan volume produksi, abnormalitas terjadi ketika terdapat satu bulan yang volume produksinya meningkat pesat. Secara kebetulan, pada bulan tersebut perusahaan sedang menerima pesanan langka dalam rangka ulang tahun ke-50 salah satu konsumen terbesarnya. Jika data peningkatan pesat pada bulan tersebut diikutsertakan dalam pembangunan model peramalan, maka model tersebut akan meneruskan pola yang tidak relevan untuk kejadian di masa mendatang.

Selain itu, terkadang data yang dibutuhkan tidak tersedia dengan baik. Sebagai contoh, data penjualan perusahaan pada bulan tertentu tidak tersedia. Jika data yang tidak lengkap ini digunakan sebagai masukan bagi proses peramalan, hasil peramalan menjadi kurang tepat. Sama dengan kasus peningkatan pesat, model peramalan juga akan melanjutkan pola akibat *missing data* tersebut. Fenomena semacam ini dikenal sebagai fenomena GIGO (*Garbage In, Garbage Out*).

Missing data adalah ketidaktersediaan informasi untuk suatu subjek atau kasus. Tugas peneliti adalah mengidentifikasi dan melihat hubungan yang terdapat pada *missing data.* Jika dilakukan perbaikan, hasil perbaikan tersebut akan memiliki distribusi yang sama atau identik dengan distribusi data aslinya (Hair Jr, 2011). *Missing data* dapat diabaikan jika persentase data yang hilang berada pada rentang yang dapat diterima. Jika *missing data* tidak ingin diabaikan, imputasi merupakan salah satu metode yang dapat dilakukan untuk mengatasi *missing data*. Metode imputasi antara lain sebagai berikut.

1. *Mean Substitution*
   Mean substitution dilakukan dengan cara mengganti nilai *missing data* dengan rata-rata data yang tersedia. Metode ini dapat digunakan pada data numerik.

2. *Regression-Based Approach*
   Pada metode ini, analisis regresi digunakan untuk memprediksi nilai variabel *missing data* berdasarkan hubungannya dengan variabel lain pada set data. Metode ini mengasumsikan bahwa terdapat hubungan antara *missing data* dengan variabel lain yang terdapat pada set data.

3. *Case Substitution*
   Case substitution adalah metode untuk mengganti nilai data yang hilang atau tidak ada dengan nilai hasil observasi aktual. Observasi aktual tersebut dilakukan kembali dan dibuat semirip mungkin dengan kasus sebelumnya.

4. *Deck Imputation*
   Deck imputation adalah metode yang mengganti data yang hilang dengan data set dari penelitian yang sudah ada tapi memiliki kasus yang mirip. Metode imputasi data ini digunakan untuk data set multivariat. Menggunakan variabel dari data poin yang akan diimputasi dapat disesuaikan untuk mengisi data yang kosong. *Deck imputation* memiliki

2 (jenis) dengan proses penggantian nilai *missing data* yang berbeda, yaitu *cold deck imputation* dan *hot deck imputation*.

a. *Cold Deck Imputation*
   Metode ini dilakukan dengan mensubstitusikan unit-unit yang tercatat pada penelitian yang sudah ada untuk mengganti data yang hilang

b. *Hot Deck Imputation*
   Metode ini dilakukan dengan mengganti nilai *missing value* dengan suatu nilai yang didasarkan pada variabel lain yang berkorelasi pada penelitian yang sama.

5. *Random number*
   Metode imputasi ini menggunakan angka yang acak secara murni tanpa alasan konkret.

6. *Most frequent*
   Most frequent adalah metode imputasi data dengan menggunakan data yang paling sering muncul pada kategori tersebut.

Selain itu, pada tahap ini dapat diidentifikasi data *outlier*. *Outlier* adalah hasil observasi yang berbeda secara signifikan dengan data-data hasil observasi lainnya. *Outlier* dapat membuat hasil analisis data menjadi tidak representatif. Seperti halnya dalam *missing data*, terdapat dua tindakan yang dapat dilakukan untuk mengatasi *outlier*, yakni dihiraukan atau diabaikan. *Outlier* dapat diabaikan jika tidak terdapat penjelasan yang masuk akal mengenai keberadaan *outlier* dalam set data. Jika keberadaan *outlier* tersebut dapat dijelaskan, maka *outlier* tersebut harus diperhitungkan agar tidak mengganggu proses selanjutnya.

METODE PERAMALAN

Klasifikasi Metode Peramalan

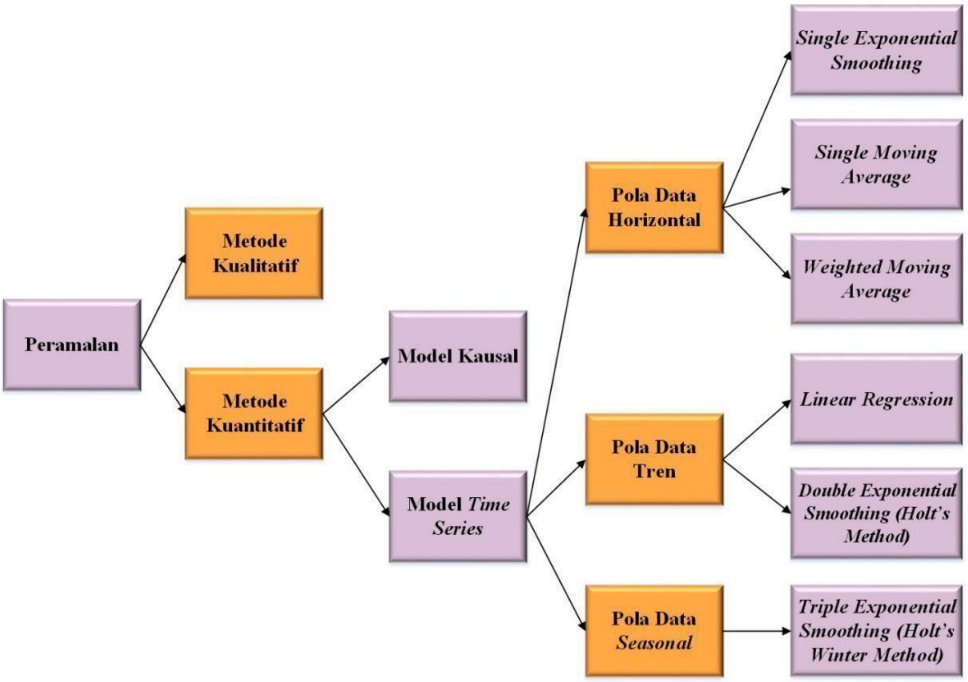

Gambar 3 Klasifikasi Metode Peramalan

Metode Peramalan Kualitatif

Metode peramalan ini sering digunakan jika data historis tidak tersedia sehingga tidak ada dasar untuk melakukan peramalan. Pada umumnya metode ini cenderung bersifat subjektif dan lebih mengandalkan informasi, pengalaman, dan intuisi. Beberapa metode peramalan kualitatif yang sering digunakan untuk memprediksi permintaan pasar antara lain (Ben-Daya, 2009).

1. *Market Survey*
   Metode peramalan ini biasanya digunakan untuk menentukan preferensi konsumen terhadap suatu produk atau jasa. Survei pasar merupakan pendekatan terintegrasi yang terdiri dari beberapa tahap, yaitu perancangan kuesioner, penyebaran kuesioner, dananalisis hasil kuesioner.

2. *Delphi Method*
   Hasil dari metode ini didasarkan pada kesepakatan sekelompok ahli. Pada umumnya kuesioner yang berisi pertanyaan-pertanyaan mengenai kondisi penjualan dan produksi perusahaan disebarkan kepada para ahli tersebut. Kelebihan dari metode ini adalah dapat menghasilkan peramalan yang cepat apabila para ahli tersedia. Kekurangan dari metode ini adalah lamanya waktu yang dibutuhkan.

3. *Jury of Executive Opinion*
   Peramalan dilakukan berdasarkan pertimbangan pihak manajemen senior perusahaan. Metode ini baik digunakan pada situasi yang sensitif dan intuitif, karena pengalaman dari para manajemen senior dapat memberikan opini yang relevan terhadap situasi yang terjadi.

4. *Historical Analogy*
   Metode ini menggunakan data-data historis produk-produk sejenis untuk meramalkan kondisi pada masa mendatang.

5. *Sales and Operations Planning*
   Metode ini mengelaborasikan perencanaan internal, terutama bagian penjualan dan operasi untuk membantu mengidentifikasi peristiwa yang akan terjadi. Contohnya pada penjualan, promosi, pengenalan produk baru, dan aktivitas lainnya yang mempengaruhi kebutuhan kapasitas produksi atau kebutuhan persediaan.

Konsep Peramalan Kuantitatif

Peramalan kuantitatif adalah suatu metode peramalan yang menggunakan data historis berupa angka. Pada peramalan kuantitatif, hasil peramalan akan sangat bergantung kepada metode yang digunakan. Penggunaan metode yang berbeda akan menghasilkan ramalan yang berbeda pula. Oleh sebab itu, diperlukan analisis lebih lanjut mengenai hasil peramalan dengan menggunakan metode tertentu. Analisis ini dilakukan dengan mengevaluasi performansi metode peramalan, yaitu membandingkan data hasil peramalan metode tersebut dengan data aktual yang tersedia. Suatu metode yang baik akan menghasilkan data hasil peramalan yang memiliki selisih yang kecil terhadap data aktual. Peramalan metode kuantitatif dapat digunakan pada kondisi sebagai berikut (Nahmias, 2009).

- Terdapat informasi tentang masa lalu.
- Informasi tersebut dapat dikuantifikasikan dalam bentuk data.
- Pola data tersebut diasumsikan akan berlanjut di masa mendatang.

Metode Peramalan Kuantitatif

Metode peramalan kuantitatif terbagi menjadi dua jenis, yaitu metode kausal dan metode deret waktu (*time series*).

Metode Peramalan Kausal

Metode peramalan kausal merupakan teknik peramalan yang menggunakan informasi satu atau beberapa variabel independen terhadap variabel-variabel dependen. Contoh kasus peramalan kausal adalah peramalan permintaan jumlah baju yang dipengaruhi oleh kenaikan gaji, pola konsumsi, tren, dan lain-lain. Salah satu teknik utama dalam metode kausal ini adalah regresi.

Model regresi adalah salah satu teknik yang digunakan untuk menjelaskan perubahan dari variabel dependen ketika variabel independen mengalami perubahan. Jenis regresi yang sering digunakan pada metode kausal adalah *multiple regression* dengan bentuk seperti yang terlihat pada persamaan (1).

$$Y = a + b_1x_1 + b_2x_2 + \cdots + b_nx_n \tag{1}$$

$dengan$
$Y\ = variabel\ dependen$
$x_n = variabel\ independen\ ke - n$
$a\ = konstanta$
$b_n = koefisien\ variabel\ independen\ ke{-}n$

Metode kausal dapat digunakan ketika perubahan suatu variabel dependen disebabkan oleh perubahan pada variabel independen. Hal tersebut menyebabkan proses identifikasi variabel menjadi sangat penting. Beberapa pedoman yang dapat dijadikan acuan untuk menerapkan metode kausal adalah sebagai berikut.

1. Terdapat alasan yang kuat untuk menganggap suatu perubahan variabel disebabkan oleh perubahan pada variabel-variabel lain. Sebagai contoh, tingkat pendapatan masyarakat akan mempengaruhi tingkat konsumsi masyarakat.

2. Terdapat indikator utama yang dapat diidentifikasi.

3. Rentang waktu atau horizon waktu peramalan yang relevan. Untuk jangka waktu pendek, rentang waktu antara pengumpulan data dan efek kausal dapat diabaikan. Namun, untuk jangka waktu yang panjang terdapat kemungkinan bahwa efek kausal telah bergeser akibat faktor rentang waktu.

Metode Peramalan *Time Series*

Metode *time series* atau biasa dikenal dengan metode deret waktu adalah metode yang menggunakan data-data pada masa lalu untuk meramalkan keadaan pada masa yang akan datang. Pada metode deret waktu ini, sumbu x menunjukkan waktu sedangkan sumbu y menunjukkan jumlah dari permintaan pada periode x.

Model Untuk Pola Data Horizontal

Naïve

Metode peramalan dengan menggunakan data permintaan aktual di periode sebelumnya sebagai data peramalan untuk periode tersebut. Metode ini mengabaikan faktor-faktor yang mampu mempengaruhi kondisi pasar atau adanya suatu tren tertentu. Oleh sebab itu, dengan pengabaian faktor ini sangat penting untuk menghitung nilai *error* atau deviasi antara hasil aktual dan peramalan. Formula metode ini ditunjukkan sebagai berikut.

$$F_t = D_{t-1}$$

dengan
F_t = *hasil peramalan pada periode t*
D_{t-1} = *data jumlah permintaan* pada periode t-1

Simple Moving Average

Salah satu metode peramalan yang ringkas dan mudah digunakan adalah *simple moving average. Simple moving average* termasuk kepada peramalan jenis *One-Step Ahead Forecast,* yaitu model peramalan yang dapat digunakan untuk meramalkan satu periode ke depan. Oleh sebab itu, untuk melakukan peramalan-peramalan di periode selanjutnya, digunakan nilai peramalan pada periode yang telah diramalkan pada satu periode ke depan tersebut. Suatu hasil peramalan *simple moving average* berorde N adalah rata-rata dari N jumlah data observasi. Untuk melakukan peramalan terhadap satu periode di depan, digunakanlah data pada N periode sebelumnya. Persamaan (2) menunjukkan cara untuk menghitung hasil peramalan dengan metode *simple moving average*.

$$F_t = \left(\frac{1}{N}\right) \sum_{i=t-N}^{t-1} D_i = \left(\frac{1}{N}\right)(D_{t-1} + D_{t-2} + \cdots + D_{t-N}) \tag{2}$$

dengan
F_t = *hasil peramalan pada periode t*
N = *moving average width*
D = *data jumlah permintaan*
t = *indeks waktu*

Single Exponential Smoothing

Metode ini memanfaatkan data hasil peramalan periode sebelumnya dan data aktual dari periode yang bersangkutan. *Single Exponential Smoothing* termasuk kepada peramalan jenis *One-Step Ahead Forecast. Exponential smoothing* bertujuan untuk melakukan penyesuaian antara hasil peramalan dengan data aktual. Persamaan (3) menunjukkan cara untuk menghitung hasil peramalan dengan metode *single exponential smoothing*.

$$F_t = \alpha \,.\, D_{t-1} + (1 - \alpha) \,.\, F_{t-1} \tag{3}$$

dengan
F_t = *hasil peramalan pada periode t*
D_{t-1} = *jumlah peramalan periode* $t - 1$
F_{t-1} = *hasil peramalan periode* $t - 1$
α = *konstanta smoothing ; dimana* $0 < \alpha \leq 1$

Weighted Moving Average

Weighted Moving Average termasuk kepada peramalan jenis *One-Step Ahead Forecast* yang identik dengan metode *single moving average.* Jika pada metode *single moving average*, setiap data aktual memiliki bobot yang sama, pada metode *weighted moving average* bobot yang berbeda-beda digunakan untuk setiap data aktual, yaitu W_i . Pemilihan bobot akan mempengaruhi galat hasil peramalan dengan data aktual. Metode matematis dari *Weighted Moving Average* dapat dilihat pada persamaan (4). Sedangkan untuk menentukan bobot, dapat digunakan persamaan (5).

$$Ft = \sum_{i=1}^{N} (W_{t-i} \times D_{t-i}) \tag{4}$$

$$W_{t-i} = \frac{t-i}{N + (N-1) + (N-2) + \cdots + 1}, 1 \leq N \leq t, i = 1, 2, \ldots, N \tag{5}$$

dengan
F_t = *hasil peramalan pada periode t*
W_{t-i} = *bobot untuk data aktual ke* $t - i$
D_{t-i} = *nilai data aktual untuk periode* $t - i$
N = *Moving average width*
t = *indeks waktu*

Model Untuk Pola Data Tren

Double Exponential Smoothing (Using Holt's Method)

Double exponential smoothing using Holt's Method termasuk kepada peramalan jenis *Multiple Step Forecast,* yaitu peramalan yang dapat digunakan untuk beberapa periode ke depan. Pada prinsipnya, metode ini mempertimbangkan terdapatnya faktor tren (β) pada data. *Beta* (β) menggunakan perubahan nilai aktual untuk memodifikasi tren peramalan dari periode sebelumnya. Untuk menghilangkan pengaruh level dan tren data peramalan, maka dibutuhkan data dari beberapa periode sebelumnya. Dikarenakan persamaan dari *double exponential smoothing using Holt's Method* membutuhkan data peramalan dari periode sebelumnya (dalam bentuk B_{t-1}dan T_{t-1}), maka dibutuhkan nilai awal untuk menginisiasikan persamaan ini. Salah satu pendekatan untuk mendapatkan nilai *intercept* dan *slope* awal adalah denganmenggunakan metode *linear regression* dengan a dan b sebagai nilai awal *intercept* dan *slope* tersebut. Persamaan (6), (7), dan (8) menunjukkan persamaan yang dibutuhkan dalam *double exponential smoothing using Holt's Method*.

$$B_t = \alpha \,.\, D_t + (1 - \alpha) \,.\, (B_{t-1} + T_{t-1}) \tag{6}$$

$$T_t = \beta \,.\, (B_t - B_{t-1}) + (1 - \beta) \,.\, T_{t-1} \tag{7}$$

$$F_{t+k} = B_t + k \,.\, T_t \tag{8}$$

dengan
D_t = *jumlah permintaan untuk periode t*
B_t = *nilai intercept untuk periode t*
B_{t-1} = *nilai intercept untuk periode* $t - 1$
T_t = *nilai slope untuk periode t*
T_{t-1} = *nilai slope untuk periode* $t - 1$
α, β = *konstanta smoothing*
F_{t+k} = *peramalan untuk k periode ke depan yang dilakukan pada periode t*

Linear Regression with Time

Linear Regression with Time termasuk kepada peramalan jenis *Multiple Step Forecast.* Metode ini bertujuan untuk mengestimasikan garis lurus berdasarkan titik-titik data yang ada. Garis tersebut terdiri dari *intercept* dan *slope.* Kedua nilai tersebut berubah seiring dengan penambahan periode peramalan. Pada metode ini waktu merupakan variabel independen.
Persamaan (9), (10), (11), (12), dan (13) menunjukkan persamaan yang dibutuhkan untuk metode ini.

$$S_{xy} = n \sum_{i=1}^{n} i.D_i - \frac{n(n+1)}{2} \sum_{i=1}^{n} D_i \tag{9}$$

$$S_{xx} = \frac{n^2(n+1)(2n+1)}{6} - \frac{n^2(n+1)^2}{4} \tag{10}$$

$$b = \frac{S_{xy}}{S_{xx}} \tag{11}$$

$$a = \bar{D} - b\frac{n+1}{2} \tag{12}$$

$$F(t) = a + bt \tag{13}$$

dengan
D_i $= jumlah\ permintaan\ pada\ periode\ ke - i$
n $= jumlah\ data\ pembentuk\ model$
b $= koefisien\ regresi\ (slope)$
a $= intercept$
$F(t) = hasil\ peramalan\ untuk\ periode\ t$

Model Untuk Pola Data *Seasonal*

Seasonal Naïve

Metode peramalan untuk data *seasonal* dengan menggunakan data historis permintaan aktual di pola *seasonal* sebelumnya sebagai data peramalan untuk pola *seasonal* saat ini. Sebagai contoh, dengan pola seasonal yang berulang sepanjang tahun, data permintaan aktual bulan Mei2024 digunakan sebagai data peramalan untuk bulan Mei 2025. Hal ini juga berlaku untuk data *seasonal* dalam rentang bulanan, triwulan, semester, atau pola *seasonal* lainnya.

Holt's Winter Method (Triple Exponential Smoothing)

Metode *Holt Winter* digunakan untuk mengatasi adanya pola data *trend* dan *seasonal*. Pada metode ini terdapat tiga jenis parameter yaitu α, β, dan γ. Metode ini juga membutuhkan nilai awal dari data peramalan sebelumnya sehingga dibutuhkan pendekatan yang sama dengan metode *double exponential smoothing using Holt's Method* untuk nilai awal tersebut. Berikut persamaan yang digunakan.

- *The seasonal factors*

$$S_t = \gamma\left(\frac{D_t}{B_t}\right) + (1-\gamma)S_{t-N} \tag{14}$$

- *The series*

$$B_t = \alpha\left(\frac{D_t}{S_{t-N}}\right) + (1-\alpha)(B_{t-1} + T_{t-1}) \tag{15}$$

- *The trend*

$$T_t = \beta(B_t - B_{t-1}) + (1-\beta)T_{t-1} \tag{16}$$

Rasio antara pengamatan permintaan terbaru dengan estimasi terkini dari permintaan basis memberikan estimasi faktor musiman saat ini. Rasio ini kemudian dirata-rata dengan estimasi terbaik sebelumnya dari faktor musiman tersebut, S_{t-N}. Setiap kali faktor musiman diperbarui, perlu dilakukan normalisasi terhadap N faktor terbaru sehingga jumlahnya menjadi N.

- Peramalan pada periode t untuk h periode ke depan

$$F_{t,t+h} = (B_t + hT_t)S_{t+h-N} \tag{17}$$

$dengan$
D_t $= nilai\ data\ aktual\ untuk\ periode\ t$
B_t $= nilai\ intercept\ untuk\ periode\ t$
T_t $= nilai\ faktor\ slope\ untuk\ periode\ t$
S_t $= nilai\ faktor\ seasonal\ untuk\ periode\ t$
$\alpha, \beta, \gamma = konstanta\ smoothing$
N $= jumlah\ periode\ dalam\ 1\ siklus$
$F_{t,t+h}$ $= nilai\ hasil\ peramalan\ untuk\ h\ periode\ ke\ depan\ yang\ dilakukan\ pada\ periode\ t + h$

Perhitungan peramalan ini dilakukan dengan asumsi $t \leq N$. Jika $N < h \leq 2N$, *seasonal factor* yang sesuai menjadi S_{t+h-2N}; jika $2N < h \leq 3N$, *seasonal factor* yang sesuai menjadi S_{t+h-3N}; dan berikutnya.

Untuk memulai metode ini, kita perlu mendapatkan estimasi awal untuk *series*, *trend* dan *seasonal factors* (*Initialization Procedure*). Winters menyarankan agar tersedia minimal dua musim data untuk inisialisasi. Misalkan tersedia tepat dua musim data, yaitu 2N data. Misal periode sekarang adalah $t = 0$, sehingga observasi sebelumnya adalah $D_{-2N+1}, D_{-2N+2}, \ldots, D_0$.

- Hitung rata-rata sampel untuk dua musim data secara terpisah.

$$V_1 = \frac{1}{N} \sum_{j=2N+1}^{-N} D_j \tag{18}$$

$$V_2 = \frac{1}{N} \sum_{j=-N+1}^{0} D_j \tag{19}$$

- Definisikan $T_0 = \frac{V_2 - V_1}{N}$ sebagai nilai *trend* awal.

- Tetapkan $B_0 = V_2 + T_0\,(\frac{N-1}{2})$. Ini mengestimasi nilai *series* saat $t = 0$.

- *Seasonal factors* awal dihitung untuk setiap periode di mana data tersedia, kemudian dirata-rata untuk mendapatkan satu set *seasonal factors*. *Seasonal factors* awal diperoleh dengan membagi setiap pengamatan awal dengan titik yang sesuai di sepanjang garis yang menghubungkan V_1 dan V_2. Hal ini dapat dilakukan menggunakan rumus berikut.

$$S_t = \frac{D_t}{V_i - \left(\frac{N+1}{2} - j\right) T_0} \quad untuk - 2N + 1 \leq t \leq 0 \tag{20}$$

  Dengan $i = 1$ untuk musim pertama, $i = 2$ untuk musim kedua, dan j adalah periode dari musim.

- Rata-ratakan *seasonal* factors. Dengan asumsi terdapat tepat dua musim data awal, diperoleh

$$S_{-N+1} = \frac{S_{-2N+1} + S_{-N+1}}{2}, \ldots, S_0 = \frac{S_{-N} + S_0}{2} \tag{21}$$

- Normalisasi *seasonal factors*

$$S_j = \left(\frac{S_j}{\sum_{i=0}^{-N+1} S_i}\right) N \; untuk - N + 1 \leq j \leq 0 \tag{22}$$

***Hyperparameter* & Parameter**

Pada metode *exponential smoothing*, α, β, dan γ merupakan *hyperparameter*. Parameter merupakan variabel dari sebuah model yang nilainya diestimasi saat *fitting* data dengan model. Contoh dari parameter model adalah koefisien dan konstanta pada model regresi. Disisi lain, *hyperparameter* merupakan parameter yang nilainya ditentukan sebelum data di-*fit* dengan model. Oleh karena itu, *hyperparameter* perlu dioptimasi untuk menghasilkan hasil yang optimal. Metode dan algoritma optimasi *hyperparameter* tidak akan dibahas pada modul ini. Selain nilai α, β, dan γ, model *exponential smoothing,* contoh *hyperparameter* adalah banyak titik data (n) yang harus diambil pada metode *moving average* dan jumlah kluster pada model *k-means clustering.*

Tabel 2 Perbedaan antara Parameter dan *Hyperparameter*

Parameter	Hyperparameter
Dibutuhkan untuk membuat prediksi (untuk performansi model)	Dibutuhkan untuk mengestimasi parameter model (untuk pembangunan model)
Diestimasi dengan algoritma optimisasi	Diestimasi dengan *hyperparameter tuning*
Tidak ditentukan oleh analis	Ditentukan oleh analis

Penentuan nilai *hyper-parameter* dapat dilakukan secara *arbitrary,* atau dengan bantuan perangkat lunak. Pada modul ini, nilai α, β, dan γ ditentukan secara *arbitrary* dan dengan bantuan perangkat lunak Microsoft Excel.

N-Step Forecasting & 1 Step Forecasting

Berdasarkan jangkauan proyeksi peramalan, terdapat 2 jenis pembagian yaitu *1-step ahead* dan *nsteps ahead*. Metode peramalan *1-step ahead* hanya dapat memproyeksikan 1 titik data setelah data masukan. Contoh metode peramalan *1-step ahead* adalah *moving average* dan *single exponential smoothing*. Sedangkan metode peramalan *n-steps ahead* tidak terbatas pada 1 titik data setelah data masukan. Contoh metode peramalan *n-steps ahead* adalah *linear regression, double exponential smoothing,* dan *triple exponential smoothing*.

UKURAN PERFORMANSI HASIL PERAMALAN

Metode peramalan kuantitatif memerlukan analisis lebih lanjut mengenai hasil peramalan. Analisis ini ditujukan untuk memilih model peramalan. Kriteria baik atau tidaknya suatu model peramalan didasarkan pada ukuran performansi yang kuantitatif sehingga pemilihan model peramalan dapat dilakukan dengan lebih baik. Ukuran performansi model peramalan adalah galat atau eror. Galat adalah selisih dari data aktual dengan data hasil peramalan suatu metode. Maka, galat dapat dihitung dengan mengurangkan data aktual dengan data hasil peramalan. Persamaan (23) menunjukkan cara dalam menghitung besarnya galat pada periode ke-t.

$$e_t = D_t - F_t \tag{23}$$

Metode peramalan yang baik akan menghasilkan data hasil peramalan yang memiliki selisih

yang kecil terhadap data aktual (Walpole, Myers, Myers, & Ye, 2012).

Ukuran performansi hasil peramalan umumnya dihitung dengan metode rata-rata galat sederhana, *mean absolute deviation* (MAD), *mean squared error* (MSE), dan *mean absolute percent error* (MAPE) (Nahmias & Olsen, 2015). Menghitung ukuran performansi dari rata-rata galat memiliki kelemahan karena adanya efek saling meniadakan ketika dua atau lebih data memiliki galat yang secara resultan (penjumlahan) saling meniadakan. Untuk menghilangkan efek ini, digunakan MAD, MSE, dan MAPE.

1. *Mean Absolute Deviation* (MAD)

   Metode MAD menghitung rata-rata perbedaan mutlak antara data aktual dan hasil peramalan. Karena dimutlakan, eror tidak akan saling meniadakan. Nilai MAD relatif terhadap data peramalan (*scale-dependent*) dan dapat ditentukan dengan persamaan

$$MAD = \frac{\sum_{t=1}^{N} |D_t - F_t|}{N} \tag{24}$$

   $dengan$
   $F_t = nilai\ hasil\ peramalan\ untuk\ periode\ t,$
   $N = banyaknya\ data, dan$
   $D_t = nilai\ data\ aktual\ untuk\ periode\ t.$

2. *Mean Squard Error* (MSE)

   Metode MSE menguadratkan nilai perbedaan antara hasil peramalan dan data aktual. Metode ini memberikan nilai yang lebih tinggi untuk titik data dengan deviasi yang besar karena menggunakan fungsi kuadrat. Metode ini dapat dipilih ketika perusahaan menginginkan eror yang lebih kecil di setiap titik data. Metode ini juga relatif terhadap data peramalan (*scale-dependent*) dan dapat dihitung dengan persamaan

$$MSE = \frac{\sum_{t=1}^{N} (D_t - F_t)^2}{N} \tag{25}$$

   $dengan$
   $F_t = nilai\ hasil\ peramalan\ untuk\ periode\ t,$

   $N = banyaknya\ data, dan$
   $D_t = nilai\ data\ aktual\ untuk\ periode\ t.$

3. *Mean Absolute Percent Error* (MAPE)

   Terakhir, metode MAPE membandingkan selisih antara data aktual dan hasil peramalan dengan data aktual. Perbandingan ini dinyatakan dalam bentuk persentase. Sebagai contoh, nilai MAPE sebesar 15 berarti rata-rata hasil peramalan terdeviasi sejauh 15% dari data aktual. Nilai MAPE dapat ditentukan dari standar perusahaan dan dapat dibandingkan dengan hasil peramalan lain (*scale-independent*). Nilai MAPE dapat dihitung dengan persamaan

$$MAPE = \frac{100}{N} \sum_{t=1}^{N} \left(\frac{|D_t - F_t|}{D_t} \right) \tag{26}$$

$dengan$
$F_t = nilai\ hasil\ peramalan\ untuk\ periode\ t,$
$N = banyaknya\ data, dan$
$D_t = nilai\ data\ aktual\ untuk\ periode\ t.$

VERIFIKASI HASIL PERAMALAN

Verifikasi hasil peramalan dilakukan untuk memverifikasi apakah fungsi peramalan yang dipilih dapat mewakili data yang ada. Metode verifikasi yang umum digunakan adalah peta kendali untuk *individual measurements* atau biasa dikenal dengan *individuals control chart* (Montgomery, 2013). Metode ini akan memeriksa kekonsistensian dan kestabilan dari proses peramalan.

Sebelum membuat *individuals control chart*, perlu dibuat *moving range control chart* untuk memeriksa variabilitas dari eror. Untuk membuat *moving range control chart*, dilakukan.perhitungan nilai *moving range* (MR) dan rata-rata nilai *moving range* ($\overline{\overline{MR}}$). Persamaan (27) dan (28) menunjukkan persamaan untuk menghitung nilai MR dan $\overline{\overline{MR}}$. Peta kendali dapat dibuat dengan menghitung batas kendali atas atau *upper control limit* (UCL), batas kendali bawah atau *lower control limit* (LCL), dan garis tengah atau *center line* (CL). UCL dihitung melalui persamaan (29), LCL untuk peta kendali ini bernilai 0, dan CL bernilai sama dengan $\overline{MR}$.

$$MR_t = |(D_t - F_t) - (D_{t-1} - F_{t-1})| \tag{27}$$

$$CL = \overline{MR} = \frac{\sum_{t=2}^{n} MR_t}{n-1} \tag{28}$$

$$UCL = D_4 \times \overline{MR} \tag{29}$$

$dengan$
$MR_t = moving\ range\ periode\ t\ (MR_1\ tidak\ ada)$
$F_t = nilai\ ramalan\ periode\ t$
$D_t = nilai\ aktual\ periode\ t$
$F_{t-1} = nlai\ ramalan\ periode\ t-1$
$D_{t-1} = nilai\ aktual\ periode\ t-1$
$n = jumlah\ data$
$CL = garis\ tengah$
$UCL = batas\ kendali\ atas$
$D_4 = nilai\ konstanta\ penyesuaian\ moving\ range\ control\ chart$

Setelah itu, *individuals control chart* juga dapat dibuat dengan menghitung UCL, LCL, dan CL. Nilai UCL dihitung melalui persamaan (30), CL dihitung melalui persamaan (31), dan LCL dihitung melalui persamaan (32).

$$UCL = \bar{x} + 3\frac{\overline{MR}}{d_2} \tag{30}$$

$$CL = \bar{x} \tag{31}$$

$$LCL = \bar{x} - 3\frac{\overline{MR}}{d_2} \tag{32}$$

$$UCL = \bar{x} + 3\frac{\bar{MR}}{d_2} \tag{30}$$

$$CL = \bar{x} \tag{31}$$

$$LCL = \bar{x} - 3\frac{\bar{MR}}{d_2} \tag{32}$$

$dengan$
$\bar{x} = rata - rata\ nilai\ pengamatan\ (rata - rata\ nilai\ eror)$
$UCL = batas\ kendali\ atas$
$CL = garis\ tengah$
$LCL = batas\ kendali\ bawah$
$d_2 = nilai\ konstanta\ penyesuaian\ individuals\ control\ chart$

Nilai MR didasari pada pasangan nilai observasi yang berurutan sehingga subgrup eror terdiri dari 2 data. Nilai MR yang telah dihitung akan dipetakan dalam *moving range control chart* dan nilai eror yang telah dihitung akan dipetakan dalam *individuals control chart*. Berikut merupakan contoh dari pasangan peta x dan peta MR pada *dataset* yang sama.

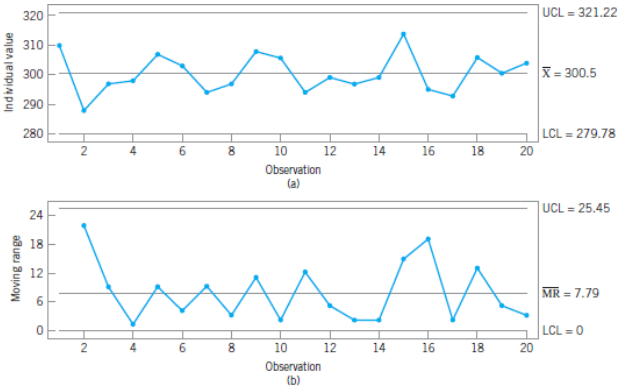

Gambar 4 Peta x (a) dan peta MR (b) (Montgomery, 2013)

Dari hasil pemetaan, dapat dilihat apakah terjadi kondisi di luar kendali (*out of control*). Jika terjadi kondisi di luar kendali, maka fungsi atau metode peramalan yang digunakan tidak sesuai sehingga peramalan yang dihasilkan tidak representatif. Bila hal ini terjadi, tambah data; lakukan/periksa kembali *data preprocessing*; dan/atau ganti metode peramalan.

Kondisi abnormalitas atau berada di luar kendali pada *moving range control chart* dapat disimpulkan jika terdapat titik yang berada di luar batas kendali (melebihi UCL) atau nilai MR secara konsisten berada di bawah CL/dekat dengan LCL (0). Untuk *individuals control chart,* digunakan *Western Electric Rules* untuk menentukan keadaan di luar kendali. *Western Electric Rules* disebut juga *Zone Rules* karena membagi peta kendali ke dalam beberapa zona. Gambaran zona dapat dilihat pada Gambar *5*.

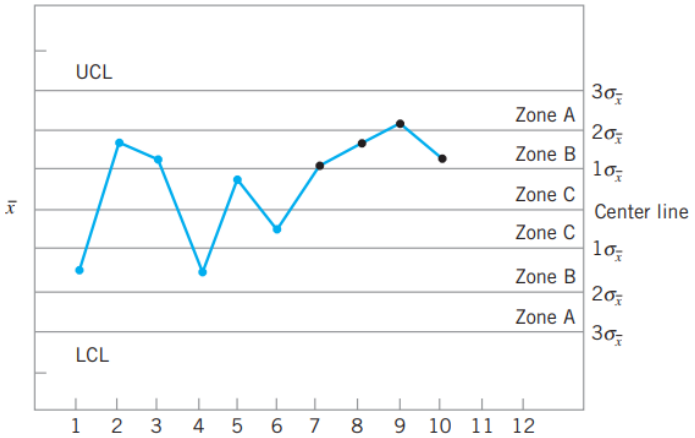

Gambar 5 Gambaran zona *individuals control chart* (Montgomery, 2013)

Batas $\pm\ 2\sigma$ digunakan untuk memisahkan zona A dan zona B sedangkan batas $\pm\ 1\sigma$ digunakan untuk memisahkan zona B dan zona C. Menurut peraturan ini, proses disimpulkan berada di luar kendali jika salah satu atau lebih hal-hal berikut ini terjadi.

1. Terdapat titik yang berada di luar batas kendali ($\pm 3\sigma$).
2. Dua titik (atau lebih) dari tiga titik berurutan berada di luar *warning limits* ($\pm 2\sigma$) pada sisi yang sama.
3. Empat titik (atau lebih) dari lima titik berurutan berada di luar batas 1σ pada sisi yang sama.
4. Delapan (atau lebih) titik berurutan berada di sisi yang sama.

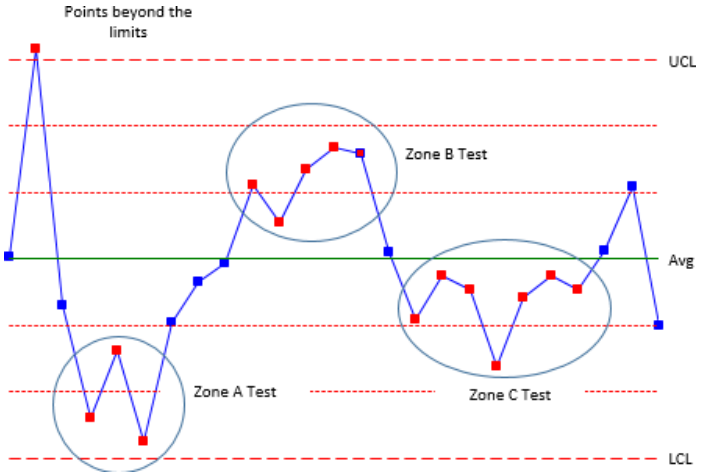

Gambar 6 Verifikasi *Control Chart*

Ditekankan kembali bahwa untuk kriteria 2, 3, dan 4, titik harus berada di sisi yang sama. Sebagai gambaran, misalkan dari tiga titik berurutan terdapat satu titik berada di atas +2 sigma dan satu titik di bawah -2 sigma. Kedua titik ini tidak berada di sisi yang sama dari garis tengah. Oleh karena itu, meskipun terdapat dua titik dari tiga titik berturut-turut yang berada di luar batas peringatan dua-sigma, masih dianggap dalam kendali.

Untuk mempermudah analisis kondisi di luar kendali, dapat dibuat empat batas kendali tambahan di *individuals control chart*. Batas-batas ini adalah $+2\sigma$, $+1\sigma$, -1σ, dan -2σ. Berikut adalah persamaan yang digunakan untuk menghitung keempat batas ini.

$$+2\sigma = \bar{x} + 2\frac{\overline{MR}}{d_2} \tag{33}$$

$$+1\sigma = \bar{x} + \frac{\overline{MR}}{d_2} \tag{34}$$

$$-1\sigma = \bar{x} - \frac{\overline{MR}}{d_2} \tag{35}$$

$$-2\sigma = \bar{x} - 2\frac{\overline{MR}}{d_2} \tag{36}$$

PERBEDAAN KORELASI, HUBUNGAN SEBAB-AKIBAT, DAN PERAMALAN

Perbedaan Korelasi dan Hubungan Sebab-Akibat

Salah satu hal yang penting untuk diperhatikan adalah memahami perbedaan antara *correlation* (korelasi), *causation* (sebab-akibat), dan peramalan (Hyndman & Athanasopoulos, 2013). Sebuah variabel x bisa jadi berguna untuk melakukan peramalan untuk variabel y, namun tidak selalu berarti bahwa x menyebabkan y. Ada kemungkinan bahwa y yang menyebabkan x atau bahkan hubungan kedua variabel tersebut lebih rumit dari sekadar hubungan sebab-akibat sederhana.

Sebagai contoh, terdapat model yang melibatkan dua variabel, yakni jumlah kasus tenggelam di pantai dengan jumlah es krim yang terjual pada periode yang sama saat musim panas. Model tersebut bisa saja memberi hasil yang baik, namun bukan berarti es krim menyebabkan adanya kasus tenggelam, namun karena masyarakat membeli es krim lebih sering saat musim panas dan di saat yang sama, mereka juga lebih sering pergi ke pantai. Dari kasus tersebut, kedua variabel (jumlah penjualan es krim dan jumlah kasus tenggelam) memiliki korelasi, namun tidak memiliki hubungan *causation.* Kedua variabel tersebut disebabkan oleh variabel lain, yakni temperatur.

Di kasus lain, seseorang dapat meramalkan apakah di siang hari akan hujan atau tidak dengan mengamati jumlah pesepeda yang melintasi jalanan. Saat jumlah pesepeda lebih sedikit dari biasanya, maka besar kemungkinan di siang hari akan hujan. Model ini dapat memberi hasil peramalan yang baik, tetapi bukan karena keberadaan pesepeda mencegah turunnya hujan, namun karena pada umumnya pesepeda akan bersepeda jika berita ramalan cuaca di hari tersebut mengatakan bahwa hari tersebut akan cerah. Pada kasus ini, terdapat hubungan sebab-akibat, namun hubungan tersebut terjadi ke arah yang berkebalikan dari model. Jumlah pesepeda turun karena adanya ramalan hujan di hari tersebut. Artinya x (hujan) menyebabkan y (pesepeda).

Perlu digarisbawahi bahwa pemahaman terkait *correlation* sangat penting bagi peramalan, walaupun tidak ada hubungan sebab-akibat antara kedua variabel tersebut ataupun korelasi berlaku ke arah sebaliknya pada model. Namun, seringkali model yang baik bisa terjadi jika mekanisme sebab-akibat bisa ditentukan. Model yang baik bagi kasus di atas akan lebih baik jika melibatkan aspek temperatur dan jumlah wisatawan serta meniadakan komponen penjualan es krim. Sementara itu pada kasus selanjutnya, model yang baik akan meniadakan komponen jumlah pesepeda, tetapi akan mempertimbangkan observasi atmosfer atau cuaca dari hari-hari sebelumnya.

Confounded Predictors

Permasalahan yang berkaitan dengan bagian ini adalah *confounding variables* (variabel yang membingungkan) (Hyndman & Athanasopoulos, 2013). Sebagai contoh, ketika kita melakukan peramalan pada *monthly sales* untuk sebuah perusahaan untuk tahun 2012 menggunakan data dari tahun 2000 hingga 2011. Pada Januari 2008, terdapat kompetitor baru yang terjun ke pasar dan mulai mengambil sebagian *market share.* Pada saat yang sama, kondisi ekonomi menurun. Pada model peramalan yang dibuat, kita memasukkan faktor kompetitor tadi (diukur dengan *advertising time* pada televisi) dan faktor kondisi ekonomi (diukur dengan GDP). Dengan ini, akan sulit atau bahkan tidak mungkin memisahkan efek dari kedua prediktor tersebut karena keduanya berkorelasi. Dapat dikatakan bahwa dua variabel adalah ***confounded*** jika efek dari variabel-variabel tersebut tidak bisa dipisahkan. Pasangan prediktor yang berkorelasi akan memiliki tingkat *confounding*-nya tersendiri, namun pada umumnya tidak dipertimbangkan sebagai *confounded variable* jika tidak ada korelasi yang tinggi antara keduanya.

Confounding bukan menjadi masalah yang besar pada peramalan, karena kita masih bisa melakukan peramalan tanpa harus memisahkan efek dari prediktor. Tetapi, hal ini dapat menjadi masalah dengan skenario peramalan karena skenario harus mempertimbangkan hubungan antar prediktor. Hal ini juga dapat menjadi masalah ketika beberapa analisis historis dari beberapa prediktor dibutuhkan.

Peramalan dan Multikolinearitas

Permasalahan lain yang berkaitan dengan peramalan adalah multikolinearitas, hal ini terjadi saat informasi yang serupa diberikan oleh dua atau lebih variabel prediktor pada *multiple regression* (Hyndman & Athanasopoulos, 2013). Multikolinearitas dapat terjadi saat dua prediktor memiliki korelasi yang tinggi satu sama lain (mendekati +1 atau -1). Pada kasus ini, kedua variabel memberikan informasi yang serupa.

Sebagai contoh, ukuran kaki dapat memprediksi tinggi badan, namun memasukkan ukuran kaki kanan dan kaki kiri secara bersamaan pada model peramalan tidak akan membuat peramalan menjadi lebih baik.

Multikolinearitas juga dapat terjadi saat terdapat hubungan yang kuat antara satu kombinasi linear prediktor dengan kombinasi linear prediktor lainnya. Pada kasus ini, kedua kelompok prediktor memberikan informasi yang sama. Sebagai contoh, perhatikan *dummy* variabel berikut. Terdapat variabel d_1, d_2, d_3, dan d_4 yang membentuk persamaan berikut.

$$d_4 = 1 - d_1 - d_2 - d_3$$

Pada persamaan di atas, dapat diketahui bahwa d_4 memiliki korelasi yang tinggi dengan $d_1 + d_2 + d_3$. Pada kasus ini, tidak mungkin untuk mengestimasi model regresi karena terdapat korelasi yang tinggi. Keberadaan multikolinearitas akan mempersulit pembuatan *statement* yang akurat terkait kontribusi dari masing-masing prediktor pada hasil peramalan.

PERAMALAN *TIME-SERIES* JANGKA PENDEK DAN JANGKA PANJANG

***Time Series* Jangka Pendek**

Penentuan jumlah *data points* yang bisa digunakan untuk metode *time series* bergantung pada jumlah parameter model yang diestimasi dan jumlah *randomness* pada data yang digunakan. Ukuran sampel yang dibutuhkan akan bertambah seiring dengan jumlah parameter yang diestimasi serta jumlah *noise* pada data (Hyndman & Athanasopoulos, 2013).

Beberapa referensi menyediakan *rule-of-thumb* terkait jumlah sampel minimum untuk model *time series.* Hal tersebut belum dapat dibenarkan karena mengabaikan variabilitas yang mendasari data yang ada dan seringkali melupakan jumlah parameter yang perlu diestimasi. Sebagai contoh, tidak ada justifikasi yang kuat pada jumlah sampel minimum sebesar 30. Satu-satunya batasan teoretis yang digunakan adalah dibutuhkan lebih banyak observasi dari jumlah parameter yang ada pada model. Namun, pada praktiknya dibutuhkan jauh lebih banyak observasi dari itu.

Time Series Jangka Panjang

Mayoritas model *time series* tidak dapat merepresentasikan hasil peramalan jangka panjang dengan baik (Hyndman & Athanasopoulos, 2013). Permasalahan yang muncul adalah data asli tidak datang dari model yang kita gunakan. Saat jumlah observasi tidak besar (contohnya 200 data), model tersebut seringkali bekerja dengan baik dan pada akhirnya akan memiliki cukup data sehingga perbedaan antara proses sebenarnya dengan model mulai terlihat jelas. Permasalahan tambahan yang muncul adalah optimalisasi parameter menjadi lebih memakan waktu karena banyaknya pengamatan yang terlibat.

Yang harus dilakukan terkait permasalahan ini adalah tergantung kepada tujuan dari model, jika kita hanya ingin melakukan peramalan untuk beberapa periode ke depan, salah satu pendekatan mudah yang dapat dilakukan adalah dengan menghapus observasi terlama dan hanya melakukan *fitting* pada model dengan data terbaru.

PENGOLAHAN DATA MENGGUNAKAN SQL SERVER MANAGEMENT STUDIO

Panduan *Export* Data

1) Pastikan *setting* pada SMSS sudah menyertakan *header* ketika menyimpan data

   Klik **Tools** pada menu→ **Options → Query Results → SQL Server → Results to Grid**

   Kemudian *checklist* tulisan "Include column headers when copying or saving the result". Apabila baru di-*checklist* setelah *query* dijalankan, maka perlu dijalankan ulang sebelum disimpan.

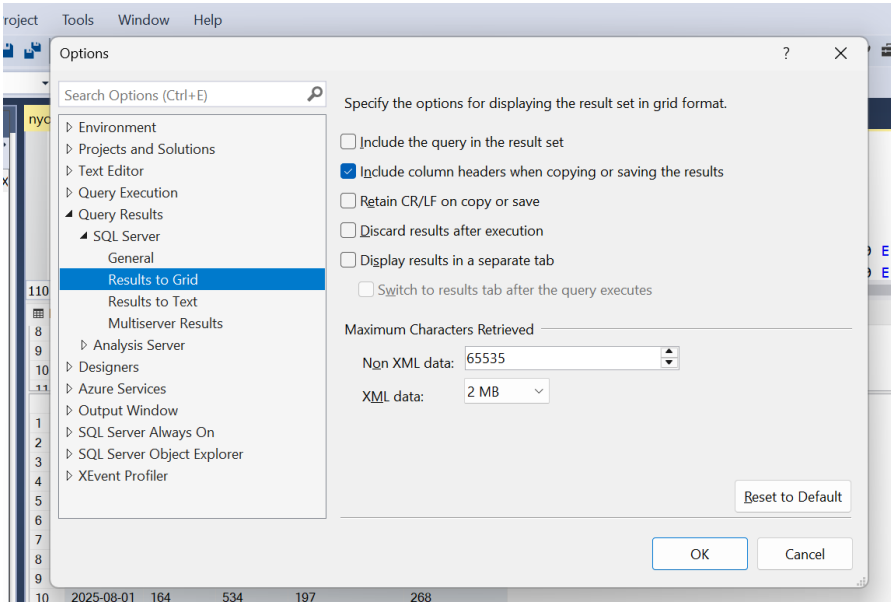

2) Blok seluruh data pada hasil grid lalu klik kanan dan pilih "Save Result As"

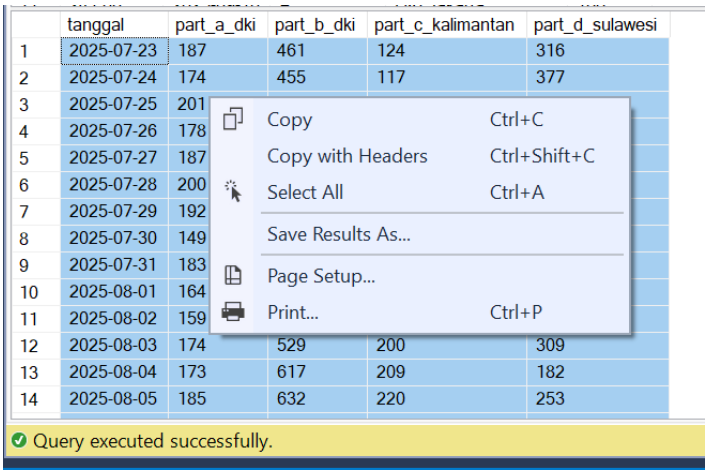

	tanggal	part_a_dki	part_b_dki	part_c_kalimantan	part_d_sulawesi
1	2025-07-23	187	461	124	316
2	2025-07-24	174	455	117	377
3	2025-07-25	201			
4	2025-07-26	178			
5	2025-07-27	187			
6	2025-07-28	200			
7	2025-07-29	192			
8	2025-07-30	149			
9	2025-07-31	183			
10	2025-08-01	164			
11	2025-08-02	159			
12	2025-08-03	174	529	200	309
13	2025-08-04	173	617	209	182
14	2025-08-05	185	632	220	253

Kemudian pilih folder penyimpanan dan simpan dalam format csv (Comma delimited) (*.csv)

PERAMALAN MENGGUNAKAN EXCEL

Estimasi *Hyperparameter*

Dalam melakukan peramalan terutama dengan metode *exponential smoothing*, diperlukan estimasi *hyperparameter*. Untuk melakukan estimasi dapat dilakukan dengan bantuan fungsi-fungsi syntax Excel FORECAST.ETS.STAT.

Pada fungsi syntax Excel tersebut memiliki argumen sebagai berikut.

- **Values (Wajib)**
  Argumen ini menyatakan nilai/data historis yang akan dilakukan peramalan.
- **Timeline (Wajib)**
  Argumen ini menyatakan array independen atau rentang data numerik. Tanggal dalam timeline harus memiliki urutan yang konsisten dan tidak boleh nol. Timeline tidak harus diurutkan, karena FORECAST.ETS.STAT akan mengurutkannya secara otomatis untuk perhitungan.
- **Statistic_type (Wajib)**
  Argumen ini menyatakan nilai numerik dengan rentang 1 sampai 8 yang menyatakan statistik hiperparameter yang akan dilakukan estimasi.
  1: α (alpha)
  2: β (beta)
  3: γ (gamma)
  4: MASE metric
  5: SMAPE metric
  6: MAE metric
  7: RMSE metric
  8: Step size detected
  Pada praktikum ini nilai statistic_type yang digunakan hanya 1, 2, dan 3.
- **Seasonality (Opsional)**
  Argumen ini menyatakan nilai numerik yang menyatakan seasonality. Nilai default 1 berarti Excel mendeteksi seasonality secara otomatis untuk peramalan dan menggunakan angka bulat positif untuk menentukan panjang pola musiman. Nilai 0 menunjukkan tidak ada seasonality, yang berarti prediksi akan bersifat linear. Angka bulat positif akan memberi tahu algoritma untuk menggunakan pola dengan panjang tersebut sebagai musim. Untuk nilai lainnya, FORECAST.ETS.STAT akan mengembalikan pesan error #NUM!.

- **Data completion (Opsional)**
- **Aggregation (Opsional)**

Peramalan

Untuk melakukan peramalan dapat dilakukan dengan menggunakan bantuan *syntax* Excel yaitu FORECAST.ETS. Pada fungsi syntax Excel tersebut memiliki argumen sebagai berikut.

- **Target_date (Wajib)**
  Titik data yang ingin diramal nilainya. Target_date dapat berupa tanggal/waktu atau nilai numerik.
- **Values (Wajib)**
  Argumen ini menyatakan nilai/data historis yang akan dilakukan peramalan.
- **Timeline (Wajib)**
  Argumen ini menyatakan array independen atau rentang data numerik. Tanggal dalam timeline harus memiliki urutan yang konsisten dan tidak boleh nol. Timeline tidak harus diurutkan, karena FORECAST.ETS akan mengurutkannya secara otomatis untuk perhitungan.
- **Seasonality (Opsional)**
  Argumen ini menyatakan nilai numerik yang menyatakan seasonality. Nilai default 1 berarti Excel mendeteksi seasonality secara otomatis untuk peramalan dan menggunakanangka bulat positif untuk menentukan panjang pola musiman. Nilai 0 menunjukkan tidak ada seasonality, yang berarti prediksi akan bersifat linear. Angka bulat positif akan memberi tahu algoritma untuk menggunakan pola dengan panjang tersebut sebagai musim. Untuk nilai lainnya, FORECAST.ETS akan mengembalikan pesan error #NUM!.
- **Data completion (Opsional)**
- **Aggregation (Opsional)**

PERALATAN PRAKTIKUM

Seluruh praktikan harus membawa perangkat laptop dengan baterai yang terisi penuh yang dapat mengakses *browser,* Microsoft Excel, dan Microsoft SQL.

PROSEDUR PRAKTIKUM

Langkah-langkah pengolahan data yang dilakukan dalam praktikum ini adalah sebagai berikut.

1. Mengidentifikasi *outlier* dan *missing data* pada setiap data historis penjualan dengan SQL.
2. Melakukan *pre-processing* data menggunakan SQL.
3. Melakukan konfersi data dari SQL ke Microsoft Excel.
4. Mengidentifikasi pola data beserta model peramalan yang dibutuhkan.
5. Melakukan peramalan data permintaan berdasarkan data historis berdasarkan model yang digunakan serta melakukan plot data permintaan historis dengan data peramalan.
6. Melakukan pengukuran performansi model peramalan.
7. Memilih model terbaik berdasarkan ukuran performansi model peramalan.
8. Melakukan verifikasi model peramalan.

KETENTUAN PENGUMPULAN

Pengumpulan Awal (Rabu, 24 September 2025 pukul 19.00 WIB) melalui *assignment* Microsoft Teams

Excel : PPST3_Modul1_Draft Excel_KelompokC/GXX.xlsx

SQL : PPST3_Modul1_SQL_KelompokC/GXX.sql

ZIP : PPST3_Modul1_Awal_KelompokC/GXX.zip

Pengumpulan Akhir (Rabu, 1 September 2025 pukul 23.59 WIB) melalui *assignment* Microsoft Teams

Excel : PPST3_Modul1_Excel_KelompokC/GXX.xlsx

SQL : PPST3_Modul1_SQL_KelompokC/GXX.sql

ZIP : PPST3_Modul1_Akhir_KelompokC/GXX.zip

REFERENSI

Ben-Daya, M. D.-K. (2009). *Handbook of Maintenance Management and Engineering.* London: Springer London.

Hair Jr, J. F. (2011). *Multivariate Data Analysis.* New Jersey: Prentice Hall.

Kerkkänen, A. K. (2009). Demand forecasting errors in industrial context: Measurement and impacts. *International Journal of Production Economics*, 43-48.

Montgomery, D. C. (2013). *Statistical Quality Control.* Singapore: John Wiley & Sons, Inc.

Nahmias, S. (2009). *Production and Operations Analysis 6th Edition.* Singapore: McGraw Hill.

Hyndman, J. R., & Athanasopoulos, G. (2013). *Forecasting: Principles and Practice.* Melbourne: Otexts.